

一. 代码修改

样例代码给出了使用 LM 算法来估计曲线 $y = \exp(ax^2 + bx + c)$ 参数 a, b, c 的完整过程。

1.1 请绘制样例代码中的阻尼因子 μ 随着迭代变化的曲线图

答：

阻尼因子 μ 是 Levenberg-Maquardt 法中用于限制迭代步长的参数, 引入 μ 的原因是 Gauss-Newton 法中采用的近似二阶泰勒展开只在展开点附近有较好的近似效果, 因此必须限制每次迭代过程中的步长 Δx 。

具体每一次迭代中的 μ 以 `currentLambda_` 这个成员变量出现在 `problem.cc` 文件的 `bool Problem::Solve(int iterations)` 中。

它的初始化在成员函数 `void Problem::ComputeLambdaInitLM()` 具体迭代计算在成员函数 `bool Problem::IsGoodStepInLM()`。因此只需要在 `while()` 循环中加入相关的存储或者绘图语句就可以满足题目要求。

```
1 while (!stop && (iter < iterations)) {
2     std::cout << "iter: " << iter << " , chi= " << currentChi_
3         << " , Lambda= " << currentLambda_ << std::endl;
4
5     //*****modified beginning*****
6     ofstream lambda_data("../data/lambda_data.txt", ios_base::app);
7     lambda_data << iter << "\t" << currentLambda_ << endl;
8     lambda_data.close();
9     //*****modified ending*****
10    ...
11 }
```

程序运行结果如下 (为了节省篇幅, 中间几步的数值结果这里就不放了, 图中有所表示):

```
1 Test CurveFitting start ...
2 iter : 0 , chi= 36048.3 , Lambda= 0.001
3 iter : 1 , chi= 30015.5 , Lambda= 699.051
4 ...
```

```
5 iter : 12 , chi= 91.3959 , Lambda= 0.252554
6 problem solve cost: 2.01802 ms
7 makeHessian cost: 0.898437 ms
8 -----After optimization, we got these parameters :
9 0.941842  2.09467 0.965537
10 -----ground truth:
11 1.0,   2.0,   1.0
```

上述代码将 μ 的每次迭代数据存入文件夹CurveFittingLM/data/lambda_data文件夹内, 存储格式是 n 行两列, 第一列是迭代次数, 第二列是 lambda(即 μ) 的值。然后再用 python matplotlib.plot 库将折线图画出, 画图程序draw_data.py如下所示:

```
1 #!/usr/bin/python
2 import matplotlib.pyplot as plt
3 filename = "lambda_data.txt"
4 X, Y = [], []
5 for line in open(filename, 'r'):
6     value = [float(s) for s in line.split()]
7     X.append(value[0])
8     Y.append(value[1])
9
10 plt.plot(X, Y, 'b--')
11 plt.plot(X, Y, 'ro')
12 plt.title("lambda data")
13 plt.xlabel("iterations")
14 plt.ylabel("lambda")
15 plt.savefig("./lambda_line_chart")
16 plt.show()
```

运行 python 程序之后得到折线图, 即为题目要求的 LM 阻尼因子 μ 随着迭代变化的曲线图, 结果如图 1 所示:




图 1: line chart of lambda

从图中可以看出, μ 的值先增大, 后减小, 即迭代步长 Δx 先增大, 后减小。

1.2 将曲线函数改成 $y = ax^2 + bx + c$

修改样例代码中的残差计算、雅克比计算函数等, 完成曲线参数估计。

答:

残差模块的更改只需要将原函数 $y = \exp(ax^2 + bx + c)$ 更改为 $y = ax^2 + bx + c$, 然后再减去观测值 y 即可 (在类中是成员变量 y_{-}).

$y = ax^2 + bx + c$ 分别对 a, b, c 求导得到新的雅克比函数 $[x^2, x, 1]^T$ 。然后用新的雅克比函数替换原程序中相应位置即可。关键代码如下所示:

```

1 // 计算曲线模型误差
2 virtual void ComputeResidual() override
3 {
4     Vec3 abc = vertices_[0]->Parameters(); // 估计的参数
5     // residual_(0) = std::exp( abc(0)*x_*x_ + abc(1)*x_ + abc(2) ) - y_; // 构建残差

```

```
6   residual_(0) = abc(0)*x_*x_ + abc(1)*x_ + abc(2) - y_; // 构建残差
7 }
8
9 // 计算残差对变量的雅克比
10 // 对 a, b, c 求导, 而不是对 x 求导
11 virtual void ComputeJacobians() override
12 {
13     Vec3 abc = vertices_[0]->Parameters();
14     double y = abc(0)*x_*x_ + abc(1)*x_ + abc(2);
15
16     // 误差为 1 维, 状态量 3 个, 所以是 1x3 的雅克比矩阵
17     Eigen::Matrix<double, 1, 3> jaco_abc;
18     // jaco_abc << x_ * x_ * exp_y, x_ * exp_y, 1 * exp_y;
19     jaco_abc << x_ * x_, x_, 1;
20     jacobians_[0] = jaco_abc;
21 }
```

程序运行结果如下所示:

```
1 Test CurveFitting start ...
2 iter : 0 , chi= 315486 , Lambda= 1.95033
3 iter : 1 , chi= 91.4713 , Lambda= 0.650111
4 iter : 2 , chi= 91.3951 , Lambda= 0.216704
5 iter : 3 , chi= 91.395 , Lambda= 0.144469
6 problem solve cost: 1.01164 ms
7 makeHessian cost: 0.509846 ms
8 -----After optimization, we got these parameters :
9 1.00611 1.96185 0.995133
10 -----ground truth:
11 1.0, 2.0, 1.0
```

阻尼因子 $\mu(\text{lambda})$ 随迭代步变化的折线图如图 2 所示:

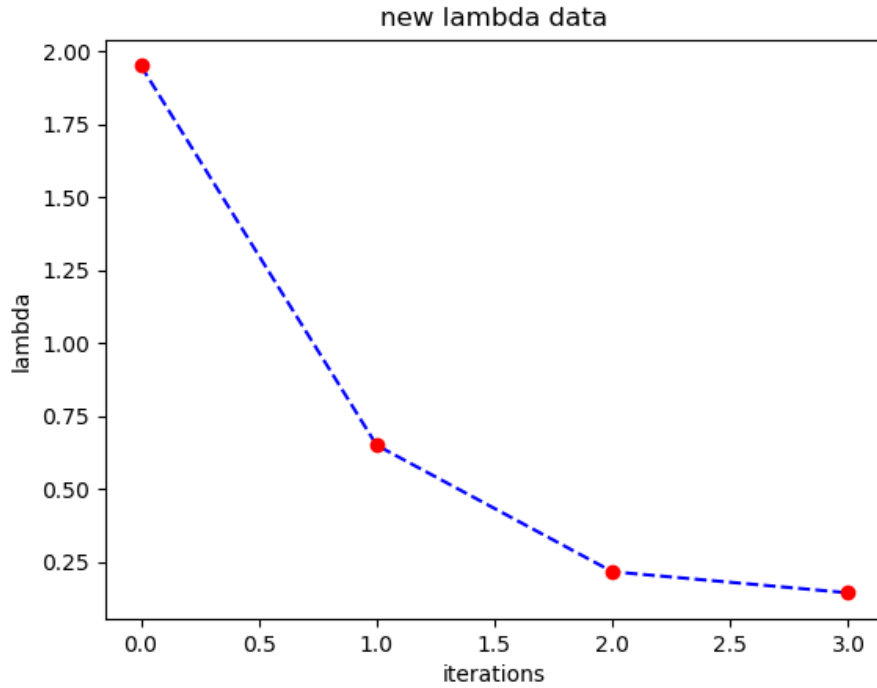


图 2: line chart of new_lambda

可以看出，其迭代步数较少，程序运行时间也比较短，可能因为这个函数比较简单，求解起来更加容易。

1.3 实现其他阻尼因子策略，并给出实验对比

阻尼因子策略参考论文 [1]4.1.1 节。该节总结了 3 种阻尼因子更新策略，其更新算法如下：

4.1.1 Initialization and update of the L-M parameter, λ , and the parameters \mathbf{p}

In `lm.m` users may select one of three methods for initializing and updating λ and \mathbf{p} .

1. $\lambda_0 = \lambda_o$; λ_o is user-specified [8].
use eq'n (13) for \mathbf{h}_{lm} and eq'n (16) for ρ
if $\rho_i(\mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$; $\lambda_{i+1} = \max[\lambda_i/L_4, 10^{-7}]$;
otherwise: $\lambda_{i+1} = \min[\lambda_i L_4, 10^7]$;
2. $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$; λ_o is user-specified.
use eq'n (12) for \mathbf{h}_{lm} and eq'n (15) for ρ
 $\alpha = \left(\left(\mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right) / \left((\chi^2(\mathbf{p} + \mathbf{h}) - \chi^2(\mathbf{p})) / 2 + 2 \left(\mathbf{J}^T \mathbf{W} (\mathbf{y} - \hat{\mathbf{y}}(\mathbf{p})) \right)^T \mathbf{h} \right)$;
if $\rho_i(\alpha \mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \alpha \mathbf{h}$; $\lambda_{i+1} = \max[\lambda_i / (1 + \alpha), 10^{-7}]$;
otherwise: $\lambda_{i+1} = \lambda_i + |\chi^2(\mathbf{p} + \alpha \mathbf{h}) - \chi^2(\mathbf{p})| / (2\alpha)$;
3. $\lambda_0 = \lambda_o \max[\text{diag}[\mathbf{J}^T \mathbf{W} \mathbf{J}]]$; λ_o is user-specified [9].
use eq'n (12) for \mathbf{h}_{lm} and eq'n (15) for ρ
if $\rho_i(\mathbf{h}) > \epsilon_4$: $\mathbf{p} \leftarrow \mathbf{p} + \mathbf{h}$; $\lambda_{i+1} = \lambda_i \max[1/3, 1 - (2\rho_i - 1)^3]$; $\nu_i = 2$;
otherwise: $\lambda_{i+1} = \lambda_i \nu_i$; $\nu_{i+1} = 2\nu_i$;

只实现了 algorithm 1 和 algorithm 3, algorithm 2 总是在第一次迭代后结束，看到作业讲

评里面，algorithm 2 的效果并不是很强，就不想 debug 了，休息一下，哈哈。算法 1 和算法 3 的运行结果下所示：

```
1 Algorithm 1=====
2 Test CurveFitting start ...
3 iter : 0 , chi= 36048.3 , Lambda= 0.001
4 iter : 1 , chi= 28146.3 , Lambda= 196.84
5 ...
6 iter : 9 , chi= 91.3959 , Lambda= 0.00608628
7 problem solve cost: 1.77909 ms
8 makeHessian cost: 0.872804 ms
9 -----After optimization, we got these parameters :
10 0.941867 2.09463 0.965551
11 -----ground truth:
12 1.0, 2.0, 1.0
13
14 Algorithm 3=====
15 Test CurveFitting start ...
16 iter : 0 , chi= 36048.3 , Lambda= 0.001
17 iter : 1 , chi= 30015.5 , Lambda= 699.051
18 ...
19 iter : 12 , chi= 91.3959 , Lambda= 0.252554
20 problem solve cost: 2.01802 ms
21 makeHessian cost: 0.898437 ms
22 -----After optimization, we got these parameters :
23 0.941842 2.09467 0.965537
24 -----ground truth:
25 1.0, 2.0, 1.0
```

总结：Algorithm 1 的效果比 Algorithm 3 略好，迭代次数更少，求解所用时间也更少，但两种方法对状态变量的估计结果是差不多的。两种方法的 lambda 随迭代次数变化折线图如图 3 所示：

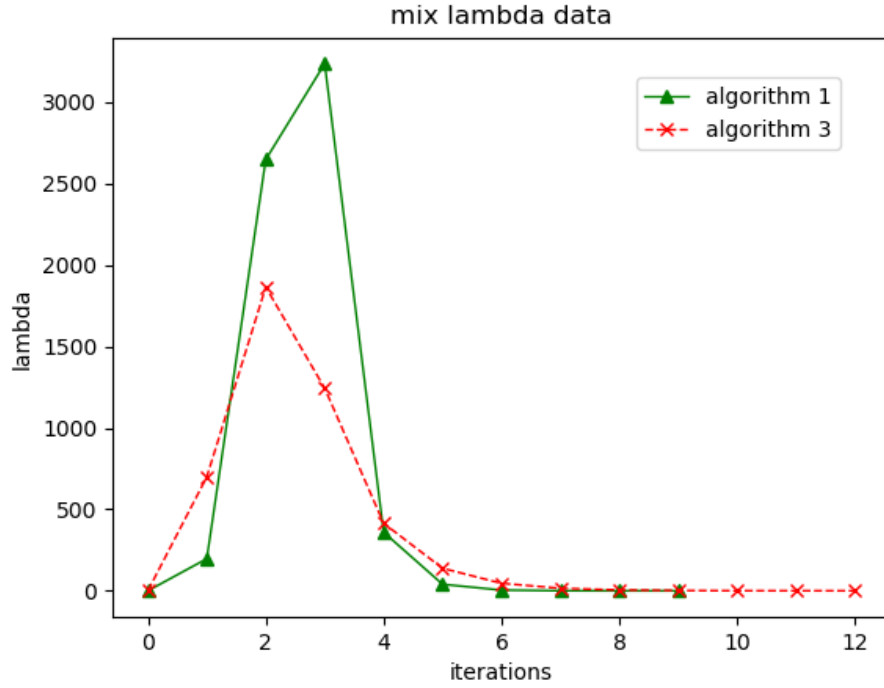


图 3: mix line chart of lambda using different algorithms

二. 公式推导

题目：根据课程知识，完成 F, G 中如下两项的推导过程：

$$1) f_{15} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta b_k^g} = -\frac{1}{4} (R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} \delta t^2) (-\delta t)$$

$$2) g_{12} = \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta n_k^g} = -\frac{1}{4} (R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} \delta t^2) \left(\frac{1}{2} \delta t\right)$$

答：

需要用到的公式：

$$\begin{aligned}
 a &= \frac{1}{2} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_{k+1}} (a^{b_{k+1}} - b_k^a)) \\
 &= \frac{1}{2} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a))
 \end{aligned} \tag{1}$$

$$\begin{aligned}
\alpha_{b_i b_{k+1}} &= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} a \delta t^2 \\
&= \alpha_{b_i b_k} + \beta_{b_i b_k} \delta t + \frac{1}{2} \left(\frac{1}{2} (q_{b_i b_k} (a^{b_k} - b_k^a) + q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a)) \right) \delta t^2
\end{aligned} \tag{2}$$

(1) f_{15} :

$$\begin{aligned}
f_{15} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta b_k^g} \\
&= \frac{\partial \frac{1}{4} q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ -\frac{1}{2} \delta b_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{\partial \frac{1}{4} q_{b_i b_{k+1}} \otimes \begin{bmatrix} 1 \\ -\frac{1}{2} \delta b_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{\partial \frac{1}{4} R_{b_i b_{k+1}} \exp([- \delta b_k^g \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{\partial \frac{1}{4} R_{b_i b_{k+1}} (I + [- \delta b_k^g \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial \delta b_k^g} \\
&= \frac{\partial \frac{1}{4} R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a) \delta t^2]_{\times} (-\delta b_k^g \delta t)}{\partial \delta b_k^g} \\
&= \frac{1}{4} (R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)]_{\times} \delta t^2) (-\delta t)
\end{aligned} \tag{3}$$

(2) g_{12} , 根据公式 (2), 有:

$$\begin{aligned}
 g_{12} &= \frac{\partial \alpha_{b_i b_{k+1}}}{\partial \delta n_k^g} \\
 &= \frac{\partial \frac{1}{4} q_{b_i b_k} \otimes \begin{bmatrix} 1 \\ \frac{1}{2} \omega \delta t \end{bmatrix} \otimes \begin{bmatrix} 1 \\ \frac{1}{4} \delta n_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_k^g} \\
 &= \frac{\partial \frac{1}{4} q_{b_i b_{k+1}} \otimes \begin{bmatrix} 1 \\ \frac{1}{4} n_k^g \delta t \end{bmatrix} (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_k^g} \\
 &= \frac{\partial \frac{1}{4} R_{b_i b_{k+1}} \exp(I + [\frac{1}{2} n_k^g \delta t]_{\times}) (a^{b_{k+1}} - b_k^a) \delta t^2}{\partial n_k^g} \\
 &= \frac{\partial - \frac{1}{4} R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a) \delta t^2]_{\times} (\frac{1}{2} n_k^g \delta t)}{\partial n_k^g} \\
 &= -\frac{1}{4} (R_{b_i b_{k+1}} [(a^{b_{k+1}} - b_k^a)_{\times} \delta t^2] (\frac{1}{2} \delta t))
 \end{aligned} \tag{4}$$

三. 证明 PPT 中公式 (9)

PPT 中公式 (9):

$$\Delta x_{lm} = - \sum_{j=1}^n \frac{v_j^{\top} F'^{\top}}{\lambda_j + \mu} v_j$$

证明: 根据 LM method 中阻尼因子 μ 的引入, 有:

$$\begin{aligned}
 (J^{\top} J + \mu I) \Delta x_{lm} &= (V \Lambda V^{\top} + \mu I) \Delta x_{lm} \\
 &= (V (\Lambda + \mu I) V^{\top}) \Delta x_{lm} \\
 &= -J^{\top} f = -F'^{\top}
 \end{aligned} \tag{5}$$

可得：

$$\begin{aligned}
 \Delta x_{lm} &= -V(\lambda + \mu I)^{-1}V^\top F'^\top \\
 &= -\begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} \frac{1}{\lambda_1 + \mu} & & & \\ & \frac{1}{\lambda_2 + \mu} & & \\ & & \ddots & \\ & & & \frac{1}{\lambda_n + \mu} \end{bmatrix} \begin{bmatrix} v_1^\top \\ v_2^\top \\ \vdots \\ v_n^\top \end{bmatrix} F'^\top \\
 &= -\begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \begin{bmatrix} \frac{v_1^\top F'^\top}{\lambda_1 + \mu} \\ \frac{v_2^\top F'^\top}{\lambda_2 + \mu} \\ \vdots \\ \frac{v_n^\top F'^\top}{\lambda_n + \mu} \end{bmatrix} \tag{6} \\
 &= -\left(\frac{v_1^\top F'^\top}{\lambda_1 + \mu} v_1 + \frac{v_2^\top F'^\top}{\lambda_2 + \mu} v_2 + \dots + \frac{v_n^\top F'^\top}{\lambda_n + \mu} v_n \right) \\
 &= -\sum_{j=1}^n \frac{v_j^\top F'^\top}{\lambda_j + \mu} v_j
 \end{aligned}$$

证毕。

参考文献

- [1] Gavin, H. P. (2019). The Levenberg-Marquardt algorithm for nonlinear least squares curve-fitting problems. Department of Civil and Environmental Engineering, Duke University, 1-19.